


- Mónica Salvatierra – 22249
- Paula Barillas – 22764
- Derek Arreaga – 22537
- Juan Pablo Solís – 22102

PROYECTO 3


ENTREGA 3

ANTERIORMENTE

	Característica	Importancia
8	price_mean_per_order	0.847128
0	order_size	0.125492
9	freight_value	0.008031
2	customer_state	0.006788
5	delivery_delay	0.005248
7	payment_installments	0.003013
1	review_score	0.002314
4	highest_category_value	0.001234
6	payment_type	0.000676
3	purchased_category_frequency	0.000074




CORRELACIÓN



NUEVAS FEATURES


- **estimated_delivery_days:** Días laborables entre order_approved_at y order_estimated_delivery_date (usando np.busday_count).
- **actual_delivery_days:** Días laborables entre order_approved_at y order_delivered_customer_date.
- **delivery_time_delta:** Diferencia entre actual_delivery_days y estimated_delivery_days.
- **is_late:** 1 si delivery_time_delta > 0, 0 si no.
- **total_order_value:** $(\text{avg_item_price} * \text{num_items}) + (\text{avg_freight_value} * \text{num_items})$.
- **freight_ratio:** $\text{avg_freight_value} / \text{avg_item_price}$ (0 si avg_item_price es 0).
- **purchase_day_of_week:** Día de la semana de order_purchase_timestamp (0 = Lunes, 6 = Domingo).

CORRELACIÓN



Model	F1-Score (Mean)	F1-Score (Std)	Accuracy (Mean)	Accuracy (Std)
Logistic Regression	0.788796	0.005335	0.81770	0.003903
K-NN	0.772280	0.004022	0.79430	0.004526
Naive Bayes	0.671871	0.164929	0.67910	0.160639
Decision Tree	0.786811	0.004928	0.81990	0.002935
Random Forest	0.784726	0.003996	0.81575	0.003017
SVM Linear	0.788255	0.005806	0.81845	0.004400
SVM RBF	0.786969	0.006765	0.81830	0.005051





REGRESIÓN LOGÍSTICA

Logistic Regression:

F1-Score: 0.789 ± 0.005

Accuracy: 0.818 ± 0.004

- Rendimiento sólido y estable, ideal para ordenar clientes por probabilidad de reseña "Buena".
- Adecuada para campañas de mejora de satisfacción.

K-NN

K-NN:

F1-Score: 0.772 ± 0.004

Accuracy: 0.794 ± 0.005

- Rendimiento aceptable, pero más lento y menos preciso.
- Útil para explorar relaciones no lineales.

NAIVE BAYES

Naive Bayes:

F1-Score: 0.672 ± 0.165

Accuracy: 0.679 ± 0.161

- Peor rendimiento con alta variabilidad, no recomendado.
- Probabilidades útiles, pero menos efectivo.

ÁRBOL DE DECISIÓN

Decision Tree:

F1-Score: 0.787 ± 0.005

Accuracy: 0.820 ± 0.003

- Mejor Accuracy, interpretable para identificar factores clave.
- Ideal para explicar reseñas (ej., entregas tardías).

RANDOM FOREST

Random Forest:

F1-Score: 0.785 ± 0.004

Accuracy: 0.816 ± 0.003

- Alta precisión y estabilidad, ideal para maximizar rendimiento.
- Menos interpretable, pero robusto.

CONCLUSIÓN

Los modelos Árbol de Decisión y Regresión Logística destacaron con las mayores Accuracy (0.820 y 0.818) y F1-Scores competitivos (0.787 y 0.789). Random Forest ofreció un rendimiento similar, ideal para maximizar precisión. Naive Bayes fue el menos efectivo debido a su alta variabilidad y bajo rendimiento.