

ANÁLISIS COMPARATIVO DE MODELOS DE REGRESIÓN Y CLASIFICACIÓN UTILIZANDO EL DATASET DEL E-COMMERCE BRASILEÑO OLIST

Autores:

Derek Fabian Arreaga | Mónica Alejandra Salvatierra | Juan Pablo Solis | Paula Rebeca Barillas

INTRODUCCIÓN

El análisis de datos es crucial para decisiones estratégicas en e-commerce, como demuestra el caso de Olist, plataforma brasileña que conecta vendedores con marketplaces. El proyecto trabajó con datasets de pedidos, productos, clientes, entregas, pagos y vendedores para obtener información valiosa. Aunque inicialmente buscaba predecir la satisfacción del cliente, tras resultados inconsistentes en la exploración inicial, se reorientó hacia el análisis de la cantidad de ítems por pedido. Este enfoque permitió estudiar el comportamiento de compra de los usuarios para generar insights útiles para departamentos de logística y marketing, identificando pedidos con mayor valor potencial o complejidad operativa.

OBJETIVOS

Objetivo General:

- Aplicar técnicas de análisis predictivo y minería de datos para identificar patrones asociados al número de productos por pedido en la plataforma de Olist.

Objetivos Específicos:


- Analizar la distribución y correlación de variables clave relacionadas con el número de ítems por pedido, identificando aquellas con mayor potencial predictivo.
- Diseñar modelos de regresión y clasificación que permitan estimar o clasificar la cantidad de productos por pedido, agrupando las órdenes en categorías representativas según su volumen.
- Evaluar el desempeño de los modelos mediante métricas apropiadas y aplicando las técnicas pertinentes para mejorar la calidad del aprendizaje.
- Generar recomendaciones accionables para la empresa, basadas en los hallazgos del análisis, que puedan ser utilizadas para optimizar procesos logísticos y apoyar futuras estrategias comerciales.

METODOLOGÍA


El estudio siguió un proceso estructurado que incluyó: (1) carga e integración de datos CSV usando el identificador de orden como referencia, (2) limpieza y preprocesamiento con generación de variables derivadas clave (delivery_days, purchase_dayofweek, num_items), (3) tratamiento de valores nulos mediante eliminación selectiva e imputación, y (4) codificación y escalado de variables. El análisis exploratorio, apoyado por Pandas Profiling, reveló correlaciones significativas entre num_items y otras variables (freight_value, payment_value, product_weight_g, product_photos_qty), justificando su selección como variable objetivo. La distribución mostró predominio de pedidos con pocos ítems, lo que orientó la selección de modelos analíticos. Se complementó con análisis de agrupamiento usando K-means para identificar segmentos de comportamiento.

RESULTADOS

Gráfica 1. Modelos de regresión utilizando validación cruzada



Gráfica 2. Modelos de clasificación utilizando validación cruzada



DISCUSIÓN

En el análisis gráfico de los modelos predictivos implementados, se evidencia un desempeño superior del algoritmo Random Forest tanto en tareas de regresión como de clasificación. En regresión, este modelo alcanzó un R² de 0.7 con validación cruzada, significativamente mayor que los valores obtenidos por regresión lineal múltiple (0.33) y árboles de decisión simples (0.34), demostrando su capacidad para capturar relaciones complejas entre las variables predictoras y la cantidad de ítems por pedido. Su bajo error (MAE=0.067, RMSE=0.243) confirma la precisión de sus predicciones. En clasificación, Random Forest logró el mejor equilibrio entre precisión (0.77) y exhaustividad (0.80), con un F1-score de 0.78, superando a la regresión logística (0.63) y árboles de decisión (0.69). Este rendimiento sobresaliente se debe probablemente a su capacidad para manejar eficientemente tanto las relaciones no lineales como el desbalance presente en las clases minoritarias, particularmente en pedidos con 3 o más ítems. La red neuronal, aunque con buen desempeño general (F1=0.69), no superó al Random Forest, sugiriendo que la complejidad adicional no aporta ventajas significativas para este conjunto de datos específico.

CONCLUSIÓN

El modelo Random Forest resultó ser el más eficaz para predecir la cantidad de ítems por pedido en Olist, con buen desempeño en regresión (R²=0.7) y clasificación (F1-score=0.78), lo que mejora la planificación logística y de inventario. Las variables freight_value, payment_value y product_weight_g fueron los principales predictores, revelando que los clientes consideran el costo-beneficio del envío al decidir cuántos productos comprar. Al cambiar el enfoque del estudio hacia la predicción de ítems por pedido, se obtuvieron resultados más útiles y aplicables, que permiten a Olist optimizar procesos y estrategias comerciales.