



PROYECTO 3

Entrega 5


Por: Mónica Salvatierra – 22249

Paula Barillas – 22764

Derek Arreaga – 22537

Juan Pablo Solis – 22102

Objetivos




Objetivo General: identificar patrones asociados al número de productos por pedido en la plataforma de Olist.

Objetivos Especificos:

- Identificar variables clave que influyen en la cantidad de ítems por pedido.
- Diseñar modelos de regresión y clasificación para predecir o categorizar el volumen de productos por orden.
- Evaluar el rendimiento de los modelos con métricas adecuadas para mejorar su precisión.
- Generar recomendaciones útiles para optimizar procesos logísticos y estrategias comerciales.



Descripción General de los datos



Dataset utilizado

Variable	Descripción
<i>payment_value</i>	Valor total pagado por el cliente.
<i>payment_installments</i>	Número de cuotas utilizadas en el pago.
<i>freight_value</i>	Costo del envío.
<i>product_weight_g</i>	Peso del producto en gramos.
<i>delivery_days</i>	Días entre la compra y la entrega.
<i>product_description_length</i>	Longitud del texto de la descripción del producto.
<i>product_name_length</i>	Longitud del nombre del producto.
<i>order_status_delivered</i>	Variable binaria: 1 si fue entregado, 0 en otros casos.
<i>payment_type_credit_card</i>	Variable binaria para método de pago con tarjeta de crédito.
<i>payment_type_debit_card</i>	Variable binaria para tarjeta de débito.
<i>payment_type_unknown</i>	Variable binaria para pagos sin categoría definida.
<i>payment_type_voucher</i>	Variable binaria para pagos con vales o cupones.
<i>customer_state</i>	Estado del cliente.
<i>seller_state</i>	Estado del vendedor.
<i>product_category_name_english</i>	Categoría del producto en inglés.
<i>review_score</i>	Puntuación del cliente (1 a 5).
<i>product_photos_qty</i>	Número de fotos asociadas al producto.
<i>purchase_dayofweek</i>	Día de la semana en que se realizó la compra (0 = lunes, ..., 6 = domingo).
<i>num_items</i>	Número total de ítems en la orden.

Preprocesamiento y limpieza




- **Limpieza:** Unificación y estandarización del dataset, eliminación de columnas redundantes.
- **Ingeniería de variables:** Nuevas variables como `delivery_days`, `purchase_dayofweek` y `num_items`.
- **Selección de atributos:** Conservación de columnas relevantes para el análisis.
- **Nulos:** Eliminación de filas críticas y tratamiento con mediana o categoría 'missing'.
- **Codificación y escalado:** One-Hot para variables categóricas y escalado estándar para numéricas.




Análisis Exploratorio

Matriz de correlacion



distribución de la variable num_items



Creación de variable objetivo



- Se creó `num_items_class` a partir de `num_items` para modelos clasificatorios.
- **Clases definidas:**
 - **Clase 0:** 1 ítem
 - **Clase 1:** 2 ítems
 - **Clase 2:** 3 o más ítems
- **Objetivo:** facilitar el modelado, mejorar la interpretación y balancear las clases.




División de Datos y Validación

- Se usó `train_test_split` (80% entrenamiento, 20% prueba).
- Para clasificación: división estratificada sobre `num_items_class`.
- Se aplicó SMOTE para balancear clases minoritarias.
- Se realizó validación cruzada (5-fold) para mayor estabilidad en métricas.



Modelos De Regresión




Valores Obtenidos:

R^2 : 0.2251

MAE: 0.1910


RMSE: 0.3758

Modelos De Regresión




Valores Obtenidos:
 R^2 : 0.3452
MAE: 0.1926
RMSE: 0.3452

Modelos De Regresión



Valores Obtenidos:
 R^2 : 0.2351
MAE: 0.1719
RMSE: 0.3734

Modelos De Regresión




Valores Obtenidos:

R^2 : 0.3759

MAE: 0.0666


RMSE: 0.3370

Modelos De Regresión



Valores Obtenidos:
 R^2 : 0.7594
MAE: 0.0615
RMSE: 0.2094

Modelos De Regresión




Valores Obtenidos:

R^2 : 0.2023

MAE: 0.1539


RMSE: 0.3811

Modelos De Clasificación




Valores Obtenidos:
F1-score: 0.6535
Precisión (macro): 0.6529
Recall (macro): 0.8995

Modelos De Clasificación




Valores Obtenidos:
F1-score: 0.7099
Precisión (macro): 0.6618
Recall (macro): 0.7887

Modelos De Clasificación




Valores Obtenidos:
F1-score: 0.8000
Precisión (macro): 0.7814
Recall (macro): 0.8290

Modelos De Clasificación




Valores Obtenidos:
F1-score: 0.6685
Precisión (macro): 0.6829
Recall (macro): 0.8215


Modelos de Regresión con Validación Cruzada



Modelos de Clasificación con Validación Cruzada



Red Neuronal




Numero de capas ocultas: 64
Numero de Neuronas: 32

Valores Obtenidos:
F1-score: 0.6900
Recall (clases 2 y 3+): > 0.60

Insights de Negocio


Figura 19: Combinaciones frecuentes por número de ítems (2 ítems)



Proyecto 3. Minería de Datos. UVG 2025

Insights de Negocio

Figura 20: Combinaciones frecuentes por número de ítems (3 o más ítems)



Conclusiones

Conclusiones del análisis

- La mayoría de pedidos son de un solo ítem; las órdenes múltiples suelen estar relacionadas con productos del hogar.
- El costo del flete crece con los ítems, pero no de forma lineal, lo que abre oportunidades para aumentar el valor sin elevar demasiado el costo logístico.
- Los modelos clasificadores tuvieron más dificultad con clases minoritarias, resaltando la necesidad de balanceo (como SMOTE).

Conclusiones

Propuestas para uso del modelo

- Integrar el modelo de Random Forest para predecir si un pedido será unitario o múltiple en tiempo real por su capacidad de generalización.
- Aplicarlo en campañas de marketing automatizado, ofreciendo incentivos a quienes suelen comprar un solo producto.
- Aprovechar el modelo para aumentar el ticket promedio y reducir los costos por envío unitario, optimizando ingresos y logística.

Recomendaciones

- Eliminar columnas redundantes que repiten información y no aportan valor, para simplificar el modelo sin perder precisión.
- Mejorar la calidad de los datos, reforzando la validación y limpieza de campos con valores nulos o inconsistentes.
- Incluir más órdenes por usuario, ya que actualmente se trabajó solo con una orden por cliente.
- Agregar variables relevantes como historial de compra para enriquecer el análisis.