



Proyecto 3

Análisis Comparativo de Modelos de Regresión y Clasificación utilizando el Dataset del E-commerce brasileño Olist

Minería de Datos

Sección 20

Derek Fabián Arreaga Kelson - 22537

Mónica Alejandra Salvatierra Chacón - 22249

Juan Pablo Solis – 22102

Paula Rebeca Barillas Alvarez – 22764

Tabla de Contenidos

Resumen Ejecutivo	3
Introducción	4
Objetivos	5
Descripción de los Datos	5
Conjunto de datos original	5
Dataset Utilizado	6
Metodología Detallada	7
1. Carga e integración de los datos	7
2. Limpieza y Preprocesamiento	8
3. Tratamiento de valores nulos	8
4. Codificación y escalado	8
5. Análisis Exploratorio	8
i. Matriz de Correlación	9
ii. Distribución de la Variable Objetivo.....	10
iii. Análisis de Agrupamiento	10
6. Creación de la Variable Objetivo para Modelos de Clasificación	11
7. División de Datos	12
Análisis de resultados	13
Modelos de Regresión	13
Modelos de Clasificación	19
Análisis Comparativo de Modelos.....	23
Modelos de Regresión	23
Insights de Negocio.....	28
Conclusiones y Recomendaciones.....	32

Resumen Ejecutivo

El presente proyecto se llevó a cabo utilizando diversos conjuntos de datos proporcionados por la empresa de e-commerce Olist, los cuales contienen información detallada sobre pedidos, productos, clientes, vendedores y logística de entrega. Inicialmente, el objetivo principal del análisis fue desarrollar un modelo capaz de predecir el nivel de satisfacción del cliente mediante la variable `'review_score'`. Sin embargo, tras obtener resultados poco satisfactorios y al detectar patrones inconsistentes, lo que limitó el rendimiento de los modelos predictivos en esa dirección.

Ante esta situación, se optó por reevaluar el enfoque del problema, llevando a cabo una exploración más profunda y sistemática de los datos. Este análisis permitió identificar nuevas oportunidades de valor, especialmente en torno a la dimensión logística del negocio. A partir de esta revisión, se redefinió el dataset base y se seleccionó una nueva variable objetivo: la cantidad de productos por pedido. Esta métrica representa un componente clave para anticipar la complejidad operativa de las órdenes y tiene un impacto directo en la planificación de envíos, el uso eficiente del espacio de almacenamiento, los costos de transporte, la gestión de inventarios y diseñar estrategias de marketing dirigidas a fomentar compras más completas, incentivando así el uso de la plataforma.

Para modelar esta variable, se realizó un trabajo completo de limpieza de datos, imputación de valores faltantes, generación de nuevas variables y evaluación de diversos modelos de regresión y clasificación para posteriormente comparar los resultados. Tras comparar múltiples modelos, el modelo de Random Forest fue seleccionado por su desempeño superior, logrando un F1-Score de 0.8 sin validación cruzada y 0.78 con validación cruzada de 5 particiones, lo que nos permite realizar predicciones con un nivel de precisión aceptable para entornos operativos.

Introducción

El análisis de datos se ha convertido en una herramienta esencial para la toma de decisiones estratégicas en empresas de comercio electrónico. Olist, una plataforma brasileña de e-commerce que conecta vendedores con múltiples marketplaces, cuenta con una gran cantidad de datos que reflejan distintas etapas del ciclo de una orden: desde la compra y el procesamiento hasta el intento de entrega o cancelación.

En este proyecto, se trabajó con múltiples datasets relacionados con pedidos, productos, clientes, entregas, pagos y vendedores. Estos datos representan una oportunidad valiosa para extraer información que permita optimizar procesos logísticos, mejorar la experiencia del cliente y apoyar la planificación operativa. Inicialmente, se planteó como objetivo predecir la satisfacción del cliente. No obstante, tras una primera exploración con resultados inconsistentes, se decidió reevaluar el enfoque del análisis.

A partir de este proceso, se redefinió el problema y se seleccionó como nueva variable objetivo, correspondiente a la cantidad de ítems por pedido. Este cambio permitió centrar el análisis en el comportamiento de compra de los usuarios, con el fin de generar insights que permitan analizar tendencias de compra y plantear escenarios de utilidad para áreas como logística y marketing, al identificar tipos de pedidos con mayor valor potencial o complejidad operativa.

Objetivos

- Objetivo General:
 - Aplicar técnicas de análisis predictivo y minería de datos para identificar patrones asociados al número de productos por pedido en la plataforma de Olist.
- Objetivos Específicos:
 - Analizar la distribución y correlación de variables clave relacionadas con el número de ítems por pedido, identificando aquellas con mayor potencial predictivo.
 - Diseñar modelos de regresión y clasificación que permitan estimar o clasificar la cantidad de productos por pedido, agrupando las órdenes en categorías representativas según su volumen.
 - Evaluar el desempeño de los modelos mediante métricas apropiadas y aplicando las técnicas pertinentes para mejorar la calidad del aprendizaje.
 - Generar recomendaciones accionables para la empresa, basadas en los hallazgos del análisis, que puedan ser utilizadas para optimizar procesos logísticos y apoyar futuras estrategias comerciales.

Descripción de los Datos

Conjunto de datos original


El conjunto de datos utilizado en este proyecto fue obtenido de la plataforma Kaggle, específicamente del repositorio Brazilian E-Commerce Public Dataset by Olist. Este dataset contiene información detallada sobre el proceso de ventas de una tienda en línea, desde el pedido inicial hasta la entrega del producto y la evaluación del cliente. Los datos están distribuidos en múltiples archivos CSV interrelacionados, los cuales representan distintas entidades clave del negocio, como pedidos, productos, pagos, clientes, vendedores, localizaciones geográficas y reseñas.

De acuerdo con la descripción oficial del dataset en Kaggle, un mismo pedido puede incluir múltiples ítems, y cada ítem puede ser despachado por un vendedor distinto. Además, por razones de privacidad, todos los textos que identificaban tiendas o socios comerciales han sido reemplazados por nombres de casas de la serie "Game of Thrones".

Cabe mencionar que, dentro de los datos proporcionados, cada cliente realiza únicamente una orden, lo cual simplifica el análisis en ciertos aspectos y garantiza una correspondencia uno a uno entre las tablas de clientes y pedidos.

A continuación, se presenta un diagrama que muestra cómo se relacionan entre sí los distintos archivos que componen el dataset.

Figura 1: Diagrama de relaciones de los archivos csv



Proyecto 3. Minería de Datos. UVG 2025

El dataset se compone de múltiples archivos CSV, cada uno representando una entidad relevante dentro del ecosistema de e-commerce de Olist.

Dataset Utilizado

El dataframe final utilizado para el modelado contiene un total de 96,359 registros y 19 variables, resultado de la integración, limpieza y transformación de los datos originales. Entre estas variables, destacan algunas que fueron derivadas o generadas a partir de los datos fuente, como *delivery_days*, *purchase_dayofweek* y *num_items*. Esta última fue seleccionada como variable objetivo para los modelos predictivos por su relevancia y estructura relacional con otras variables del conjunto.

A continuación, se presenta una tabla con la descripción de cada una de las variables incluidas en el dataset final:

Tabla 1: Variables incluidas en el dataset final

Variable	Descripción
payment_value	Valor total pagado por el cliente.
payment_installments	Número de cuotas utilizadas en el pago.
freight_value	Costo del envío.
product_weight_g	Peso del producto en gramos.
delivery_days	Días entre la compra y la entrega.
product_description_length	Longitud del texto de la descripción del producto.
product_name_length	Longitud del nombre del producto.
order_status_delivered	Variable binaria: 1 si fue entregado, 0 en otros casos.
payment_type_credit_card	Variable binaria para método de pago con tarjeta de crédito.
payment_type_debit_card	Variable binaria para tarjeta de débito.
payment_type_unknown	Variable binaria para pagos sin categoría definida.
payment_type_voucher	Variable binaria para pagos con vales o cupones.
customer_state	Estado del cliente.
seller_state	Estado del vendedor.
product_category_name_english	Categoría del producto en inglés.
review_score	Puntuación del cliente (1 a 5).
product_photos_qty	Número de fotos asociadas al producto.
purchase_dayofweek	Día de la semana en que se realizó la compra (0 = lunes, ..., 6 = domingo).
num_items	Número total de ítems en la orden.

Proyecto 3. Minería de Datos. UVG 2025

Metodología Detallada

1. Carga e integración de los datos

Como primer paso se cargaron todos los archivos CSV relevantes y se organizaron en estructuras DataFrame para facilitar su manipulación y análisis. La integración de los datos se realizó tomando como referencia el identificador de la orden, permitiendo unificar la información clave en un solo DataFrame. Este enfoque partió desde la premisa antes vista de que cada cliente realiza una única orden, facilitando así el análisis posterior.

2. Limpieza y Preprocesamiento

Una vez unificado el dataset, se procedió a la limpieza de datos. Se eliminaron columnas redundantes creadas durante el proceso de unión y se estandarizó el formato de fechas. A partir de estas, se generaron variables derivadas como:

- *delivery_days*: Diferencia en días entre la fecha de entrega estimada y real
- *purchase_dayofweek*: día de la semana que se realizó la compra.
- *num_items* : cantidad total de productos por pedido, obtenida a partir del dataset *order_items*, agrupando por *order_id* y contando los registros asociados.

Esta variable no estaba presente directamente en los archivos originales y fue construida como parte del proceso de ingeniería de variables.

Se depuraron las columnas para conservar únicamente las consideradas más relevantes para el análisis y predicción, entre ellas: *review_score*, *order_status*, *payment_value*, *payment_installments*, *freight_value*, *num_items*, *customer_state*, *product_name_length*, *product_description_length*, *product_photos_qty*, *product_weight_g*, *seller_state*, *product_category_name_english*, y las nuevas variables derivadas anteriormente mencionadas.

3. Tratamiento de valores nulos

Se optó por eliminar las filas con datos faltantes en variables críticas como *num_items* y *delivery_days*, mientras que para variables numéricas restantes se utilizó la mediana como imputación y para las categóricas se asignó una nueva categoría llamada 'missing'.

4. Codificación y escalado

Posteriormente, se aplicaron técnicas de codificación y escalamiento de variables para preparar los datos antes del modelado. Esto incluyó el uso de escaladores estándar para variables numéricas, codificación One-Hot para variables categóricas nominales y codificación ordinal para aquellas con un posible orden implícito.

5. Análisis Exploratorio


Una vez integradas las distintas tablas del dataset original y tras llevar a cabo el proceso de limpieza, preprocesamiento y construcción de nuevas variables, se realizó un análisis exploratorio sobre el dataset final consolidado. Este análisis tuvo como objetivo principal comprender la distribución de los datos, detectar posibles relaciones entre variables, y obtener intuiciones previas que orientaran la construcción de modelos posteriores.

Para explorar la estructura general del dataset, se utilizó la herramienta Pandas Profiling, la cual permitió generar un informe automático con estadísticas descriptivas, detección de valores atípicos, correlaciones, distribuciones univariadas y otras métricas clave.

i. Matriz de Correlación

Uno de los hallazgos clave del análisis exploratorio fue la identificación de relaciones entre variables mediante la siguiente matriz de correlación:

Figura 2: Matriz de correlacion entre variables del Dataset



Proyecto 3. Minería de Datos. UVG 2025


En dicha matriz se observó que la variable `num_items` mostraba correlaciones significativas con otras variables como `freight_value`, `payment_value`, y características del producto como `product_weight_g` y `product_photos_qty`. Esta observación respaldó la decisión de utilizar `num_items` como nueva variable objetivo, al presentar una estructura relacional más sólida para el desarrollo de modelos predictivos.

La elección de esta variable como objetivo permite analizar el comportamiento de compra de los clientes, lo cual puede aportar valor en áreas clave como la planificación de inventario, la logística de envíos y el diseño de estrategias de marketing personalizadas.

ii. Distribución de la Variable Objetivo

Posteriormente, se examinó la distribución de la variable *num_items* para evaluar posibles sesgos o desbalances:

Figura 3: Distribucion de variable num_items




Proyecto 3. Minería de Datos. UVG 2025

La distribución de *num_items* evidencia una concentración alta en pedidos con pocos ítems, siendo la mayoría de una o dos unidades por orden. Este comportamiento sugiere la conveniencia de aplicar modelos adecuados para variables discretas, como modelos de regresión con regulación o enfoques de clasificación ordinal.

iii. Análisis de Agrupamiento

Adicionalmente, se realizó un análisis de agrupamiento utilizando el algoritmo *K-means*, con el objetivo de identificar posibles segmentos de comportamiento dentro del conjunto de datos.

Figura 4: Grafica de Inercia vs Número de clústers



Proyecto 3. Minería de Datos. UVG 2025

Según la gráfica del método del codo, el punto de inflexión se observa en $k = 3$, lo que sugiere que el número óptimo de clústers es 3. Esto respalda la decisión de agrupar los pedidos en tres categorías: pedidos con 1 ítem, con 2 ítems y con 3 o más ítems, para facilitar su análisis y modelado posterior.

6. Creación de la Variable Objetivo para Modelos de Clasificación

Para los modelos de clasificación se definió una variable objetivo de naturaleza multiclase, denominada *num_items_class*, a partir de la variable continua *num_items*, la cual representa la cantidad de ítems por pedido. Esta transformación permitió adaptar el problema al enfoque clasificatorio, facilitando el uso de algoritmos supervisados diseñados para variables discretas.

La variable *num_items_class* fue construida agrupando los valores de *num_items* en tres categorías con base en su frecuencia observada durante el análisis exploratorio:

- **Clase 0:** Pedidos con exactamente 1 ítem
- **Clase 1:** Pedidos con exactamente 2 ítems
- **Clase 2:** Pedidos con 3 o más ítems

Esta discretización respondió tanto a criterios de interpretabilidad como a la necesidad de contar con un número suficiente de ejemplos en cada clase para el entrenamiento robusto de los modelos. Asimismo, se realizó un filtrado previo para excluir clases con muy baja frecuencia, garantizando así una distribución más balanceada y una mayor estabilidad en las métricas de evaluación.

7. División de Datos

Para el entrenamiento de los modelos se dividieron los datos en dos conjuntos usando la función *train_test_split*, creando así los conjuntos de entrenamiento y prueba. En el caso del modelo de regresión, se empleó una división del 80% para entrenamiento y 20% para prueba sobre la variable objetivo *num_items*.

Para el caso de clasificación, se creó una nueva variable categórica llamada *num_items_class* que agrupa el número de ítems por pedido en tres clases: “1”, “2” y “3+”. También se aplicó *train_test_split()* con la opción *stratify*, lo cual garantizó que la distribución de clases se mantuviera proporcional en los conjuntos de entrenamiento y prueba, preservando la representatividad estadística de las clases minoritarias.

Debido a que algunas clases en conjunto de entrenamiento estaban desbalanceadas, se utilizó la técnica de SMOTE para aplicar un sobre muestreo, permitiendo así equilibrar la cantidad de ejemplos por clase con respecto a la clase mayoritaria, sin introducir información artificial en los datos de prueba. Esto se realizó debido a que esto mejora la capacidad del modelo para generalizar frente a clases poco representadas sin sesgar las métricas de evaluación.

Además, se implementó una etapa de validación cruzada con 5 particiones sobre el conjunto de entrenamiento. Esta técnica permitió evaluar ciertos modelos con una mayor robustez, reduciendo la varianza de las métricas de evaluación y asegurando que los resultados no dependieran únicamente de una sola división aleatoria.

Análisis de resultados


Modelos de Regresión

Para los modelos primero se realizaron los modelos de regresión, los cuales tenían como objetivo predecir la cantidad de ítems por pedido como una variable numérica continua.

Regresión Lineal

Se inició con una regresión lineal simple utilizando únicamente la variable `freight_value` como predictor, con el fin de establecer una línea base que permitiera evaluar si existía una relación directa entre el costo del envío y la cantidad de productos solicitados por el cliente.

Figura 5: Grafica num_items vs freight_value (Regresión Lineal)




Proyecto 3. Minería de Datos. UVG 2025

Este modelo obtuvo un valor de R^2 de 0.2251 lo cual indica que solo el 22.5% de la variabilidad en el número de ítems por pedido puede explicarse por el valor del flete. Además, el MAE fue de 0.1910 y el RMSE de 0.3758, métricas que reflejan un error relativamente alto y una capacidad predictiva limitada. Estos resultados confirman que, aunque `freight_value` guarda cierta relación con el número de ítems, por sí solo no es suficiente para construir un modelo lineal robusto.

Regresión Múltiple Lineal

Posteriormente se implementó una regresión lineal múltiple considerando todas las variables disponibles en el conjunto de datos. Este modelo permitió explorar la contribución conjunta de diferentes factores, como el valor total pagado, el peso del producto, el número de cuotas y otras variables logísticas, a la cantidad de ítems en una orden.

Figura 6: Grafica valores predichos vs num_items (Regresión Múltiple)




Proyecto 3. Minería de Datos. UVG 2025

El uso del resto de variables mejoró el desempeño del modelo a comparación del modelo lineal, obteniendo un R^2 de 0.3452 con un MAE de 0.1926 y un RMSE de 0.3452, lo que reflejó una mejora moderada respecto al modelo simple.

Regresión Polinomial

Luego con el objetivo de mostrar la posible existencia de relaciones no lineales en los datos se utilizó también una regresión polinomial de grado 3, aplicada nuevamente sobre freight_value.

Figura 7: Grafica num_items vs freight_value (Regresión Polinomial)




Proyecto 3. Minería de Datos. UVG 2025

Este modelo fue capaz de ajustar una curva más compleja y flexible, permitiendo detectar patrones no capturados por una simple recta, aunque limitado al uso de una sola variable. Como resultado se obtuvo un R^2 de 0.2351, un MAE de 0.1719 y un RMSE de 0.3734, valores que evidencian que una sola característica no basta para explicar adecuadamente la variabilidad en el número de ítems por pedido

Árbol de decisión

Otro de los modelos realizados fue un árbol de decisión regresor que permitió segmentar los datos mediante reglas simples y jerárquicas.

Figura 8: Grafica num_items vs freight_value (Arbol de decision)




Proyecto 3. Minería de Datos. UVG 2025

Este modelo capturó interacciones entre variables de forma automática y mostró un mejor ajuste en casos con relaciones no lineales. Sus métricas de desempeño fueron un R^2 de 0.3759, MAE de 0.0666 y RMSE de 0.3370, lo cual representó una mejora importante en la precisión de las predicciones individuales.

Para aumentar la estabilidad y reducir el sobreajuste, se utilizó un modelo de Random Forest Regressor, el cual combina múltiples árboles entrenados sobre distintos subconjuntos aleatorios.

Random Forest

Figura 9: Grafica num_items vs freight_value (Random Forest)




Proyecto 3. Minería de Datos. UVG 2025

Este enfoque potenció la capacidad predictiva y generalizó mejor en comparación con un único árbol. De hecho, fue el modelo con mejor desempeño global, con un R^2 de 0.7594, MAE de 0.0615 y RMSE de 0.2094, lo que evidencia su capacidad para modelar relaciones complejas y su bajo nivel de error.

Support Vector Regressor

Figura 10: Grafica num_items vs freight_value (SVR)




Proyecto 3. Minería de Datos. UVG 2025

Por último, se realizó un modelo SVR con kernel RBF utilizando también solo la variable freight_value. Este obtuvo un R^2 0.2023, MAE de 0.1539 y RMSE de 0.3811, siendo uno de los modelos con menor desempeño general.

Modelos de Clasificación

Regresión Logística

Figura 11: Matriz de Confusión (Regresión Logística)




Proyecto 3. Minería de Datos. UVG 2025

El primer modelo de clasificación implementado fue el de regresión Logística el cual alcanzó un F1-score de 0.6535, con valores de precisión y recall promedio (macro) de 0.6529 y 0.8995, respectivamente. Aunque su rendimiento fue sólido en la clase mayoritaria ('1'), mostró una caída significativa en la clase '3+', con un F1-score de apenas 0.53. La matriz de confusión reflejó una tendencia a confundir esta clase con '1', evidenciando las dificultades del modelo ante clases poco representadas.

Árbol de decisión

Figura 11: Matriz de Confusión (Decision Tree)




Proyecto 3. Minería de Datos. UVG 2025

Posteriormente se entrenó un árbol de decisión, que mejoró el desempeño general. Este modelo logró un F1-score de 0.7099, precisión de 0.6618 y recall de 0.7887. En comparación con la regresión logística, se observó un mejor equilibrio entre las tres clases, aunque aún persistieron errores importantes en la predicción de la clase '3+'.

Random Forest

Figura 12: Matriz de Confusión (Random Tree)




Proyecto 3. Minería de Datos. UVG 2025

El modelo de Random Forest Classifier ofreció el mejor desempeño global entre todos los modelos de clasificación probados. Alcanzó un F1-score de 0.8000, una precisión de 0.7814 y un recall de 0.8290. Su matriz de confusión mostró una clasificación más precisa incluso en las clases menos representadas, destacando su capacidad para generalizar y adaptarse a estructuras complejas gracias al ensamble de múltiples árboles.

Support Vector Classifier

Figura 13: Matriz de Confusión (SVC)



Proyecto 3. Minería de Datos. UVG 2025

Otro modelo implementado fue el Support Vector Classifier (SVC) con kernel RBF, que alcanzó un F1-score de 0.6685, precisión de 0.6829 y recall de 0.8215. Aunque su rendimiento fue razonable, no superó al modelo Random Forest y mostró mayor dificultad para distinguir entre clases intermedias.

KNN (K- Nearest Neighbors)


El modelo de K-Nearest Neighbors (KNN), con 3 vecinos y también entrenado sobre un conjunto balanceado, fue el de peor desempeño. Alcanzó un F1-score de apenas 0.4782, con una precisión de 0.4560 y un recall de 0.5407. La matriz de confusión mostró una fuerte tendencia a predecir la clase '1' para la mayoría de los ejemplos, lo que refleja su sensibilidad al desequilibrio de clases y su limitada capacidad de generalización en este contexto.

Análisis Comparativo de Modelos

Modelos de Regresión

Sin Validación Cruzada

Figura 14: Modelos de Regresión sin validación cruzada



Proyecto 3. Minería de Datos. UVG 2025

Como se observa en la Figura 14, el modelo de Regresión con Random Forest se posicionó como el más efectivo en la tarea de estimar la cantidad de ítems por pedido. Este modelo alcanzó un R^2 de 0.76, superando significativamente al resto, y obtuvo también el menor MAE (0.06) y RMSE (0.21), lo que evidencia su capacidad para capturar relaciones complejas entre las variables sin sobreajustarse.


Los modelos de Regresión Lineal Múltiple y Regresión Polinomial (grado 3) presentaron un rendimiento intermedio, con valores de R^2 cercanos a 0.35 y errores medios ligeramente superiores. Aunque captan parte de la variabilidad, su capacidad de generalización es limitada frente a modelos no lineales más robustos.

Por otro lado, el modelo de Regresión Lineal Simple obtuvo un desempeño notablemente inferior (R^2 de 0.22), demostrando que el uso de una sola variable (como `freight_value`) no es suficiente para explicar la variabilidad del número de ítems. Por otro lado, el modelo de Support Vector Regression, si bien alcanzó un MAE bajo (0.15), obtuvo el R^2 más bajo (0.20), lo que sugiere que predice cercanamente al promedio, pero no capta adecuadamente la variabilidad de los datos.

Estos resultados muestran que el uso de modelos de tipo ensamble como Random Forest permite capturar patrones más profundos y obtener predicciones más fiables, incluso sin aplicar validación cruzada.

Con Validación Cruzada

Figura 15 Modelos de Clasificación con validación cruzada



Proyecto 3. Minería de Datos. UVG 2025

Se evaluaron tres modelos de regresión utilizando validación cruzada de 5 particiones para estimar la cantidad de ítems en un pedido como una variable continua. Las métricas utilizadas fueron R^2 (coeficiente de determinación), MAE (error absoluto medio) y RMSE (raíz del error cuadrático medio).

El modelo de Random Forest Regressor mostró el mejor desempeño general, con un R^2 cercano a 0.70, lo cual indica una buena capacidad explicativa del modelo. Además, logró los valores más bajos de MAE y RMSE, lo que lo posiciona como la opción más sólida para predecir con precisión la cantidad de ítems en un pedido.


Por otro lado, tanto la regresión lineal como el árbol de decisión mostraron rendimientos similares, pero considerablemente más bajos, especialmente en términos de R^2 , lo que sugiere que no capturan adecuadamente la complejidad del comportamiento de compra.

Modelos de Clasificación

En esta etapa, se evaluaron modelos de clasificación para categorizar los pedidos según su volumen '*num_items_class*', utilizando tres clases: 1, 2 y 3+ ítems. Dado el desbalance de clases, se aplicó sobre muestreo con SMOTE dentro de un pipeline y se usaron métricas macro (F1-score, precision y recall), primero normales y luego sobre validación cruzada de 5 particiones.

Sin Validación Cruzada

Figura 16: Modelos de clasificación sin validación cruzada



Proyecto 3. Minería de Datos. UVG 2025


A partir de los resultados mostrados en la Figura 16, se observa que el modelo de Random Forest obtuvo el mejor desempeño general entre todos los modelos evaluados sin validación cruzada, alcanzando un F1-score de 0.80 y la mayor precisión (0.78). Este modelo logró un balance adecuado entre la capacidad de identificar correctamente las clases (recall de 0.82) y la precisión al evitar falsos positivos.

Por su parte, los Árboles de Decisión también mostraron un rendimiento sólido (F1-score de 0.71), lo que los posiciona como una alternativa más simple pero efectiva. Regresión Logística y SVC tuvieron un desempeño aceptable, aunque inferior, con F1-scores de 0.66 en ambas y menores

niveles de precisión. Finalmente, KNN presentó el desempeño más bajo en todas las métricas, especialmente en recall y F1-score, lo cual sugiere una capacidad baja de generalización en este caso.

Con Validación Cruzada

Figura 17: Modelos de clasificación con validación cruzada



Proyecto 3. Minería de Datos. UVG 2025

El modelo de Random Forest Classifier nuevamente destacó como el mejor clasificador, con un equilibrio muy sólido entre precisión y cobertura. Su alto F1-score sugiere un rendimiento estable incluso en clases menos representadas.


La regresión logística obtuvo el recall más alto, lo que indica que logra capturar correctamente una buena proporción de las instancias verdaderas, pero con menor precisión, lo que genera más falsos positivos. El árbol de decisión mostró un comportamiento intermedio en todas las métricas.

Red Neuronal

Finalmente, se entrenó una red neuronal multicapa (MLP) con dos capas ocultas de 64 y 32 neuronas, utilizando los datos balanceados con SMOTE. A diferencia de los modelos anteriores, la evaluación se realizó sobre el conjunto de prueba, ya que el modelo no se integró a una validación cruzada.

El rendimiento general fue similar al de otros modelos, con F1-score de 0.69, destacando su capacidad para generalizar. A pesar de ello, tiene dificultades para predecir correctamente las clases 2 y 3+, debido al desbalance y la baja frecuencia relativa de estas categorías. Aun así, es capaz de reconocerlas en una proporción razonable (recall > 0.6).


Figura 18: Matriz de Confusión (Red Neuronal)



Insights de Negocio

Para entender mejor los patrones de comportamiento de compra en la plataforma, se analizaron las órdenes según número de ítems comprados por pedido. A partir de ello, se calcularon varias métricas relevantes. Estos análisis permitieron generar visualizaciones que sirven como base para la formulación de insights estratégicos para el negocio. A continuación, se presentarán las observaciones junto a sugerencias para poder mejorar el tamaño de las órdenes:

Figura 19: Combinaciones frecuentes por número de ítems (2 ítems)




Proyecto 3. Minería de Datos. UVG 2025

Al analizar las órdenes que contienen exactamente 2 productos, se identificaron combinaciones de categorías que suelen comprarse juntas. Las más frecuentes fueron:

- bed_bath_table + furniture_decor (45 veces)
- bed_bath_table + home_comfort (36 veces)
- furniture_decor + housewares (17 veces)

Estas asociaciones sugieren que los clientes que compran productos del hogar tienden a combinar mobiliario, decoración y elementos funcionales en una sola orden. Esto podría usarse para proponer bundles o recomendaciones cruzadas en la interfaz de compra.

Figura 20: Combinaciones frecuentes por número de ítems (3 o más ítems)




Proyecto 3. Minería de Datos. UVG 2025

Cuando los clientes realizan órdenes con 3 o más productos, las combinaciones más frecuentes también incluyen categorías relacionadas al hogar:

- bed_bath_table + furniture_decor (25 veces)
- furniture_decor + garden_tools (10 veces)
- bed_bath_table + housewares (8 veces)

Esto refuerza la idea de que los compradores aprovechan órdenes grandes para renovar o complementar espacios del hogar, lo cual puede servir como base para campañas temáticas.

Figura 21: Categorías que más se repiten en una misma orden




Proyecto 3. Minería de Datos. UVG 2025

Las categorías más comúnmente repetidas (es decir, se compraron al menos dos productos iguales en una misma orden) fueron:

- bed_bath_table (1004 veces)
- furniture_decor (803 veces)
- sports_leisure (572 veces)

Esto indica que ciertas categorías no solo se compran en combinación con otras, sino que también se adquieren en múltiplos, lo que podría reflejar uso intensivo o propósito de regalo. Se recomienda habilitar descuentos por volumen o sugerencias de compra múltiple.

Figura 22: Costo promedio del flete según el tamaño de la orden



Proyecto 3. Minería de Datos. UVG 2025

A medida que el número de ítems en la orden aumenta, el costo promedio del flete también aumenta, pero a una tasa menor que lineal, especialmente en órdenes pequeñas. Por ejemplo, agregar un segundo ítem casi duplica el flete, pero entre 2 y 3 ítems el incremento es mucho más bajo proporcionalmente.

Se sugiere ofrecer un incentivo como por ejemplo de “envío gratis por 3 o más ítems” para aumentar los productos vendidos por orden, sin que el costo logístico se dispare.

Los patrones observados en la cantidad de ítems por orden muestran que las combinaciones de 2 o más productos tienden a involucrar categorías relacionadas al hogar, como *bed_bath_table*, *furniture_decor*, y *housewares*. Estas órdenes también presentan un valor promedio más alto, lo que sugiere un mayor ingreso por pedido y mayor rentabilidad logística.

Este comportamiento abre la posibilidad de intervenir proactivamente sobre órdenes con probabilidad de ser unitarias. Aquí es donde el modelo predictivo desarrollado cobra relevancia, ya que permite anticipar si una orden será de un solo ítem o no, dando la oportunidad a Olist de aplicar estrategias que fomenten la venta cruzada o el incremento de productos por orden.

Conclusiones y Recomendaciones

Conclusiones derivadas del análisis

A lo largo del análisis exploratorio y del proceso de modelado se identificaron diversos hallazgos clave que permiten comprender mejor el comportamiento de las órdenes dentro de la plataforma Olist:

- La mayoría de pedidos contienen únicamente un ítem, pero las órdenes con múltiples productos, aunque menos frecuentes, están asociadas a categorías como hogar y decoración.
- El costo promedio del flete aumenta con el número de ítems, pero de manera no lineal. Esto sugiere que las órdenes con más productos pueden representar mayor valor sin necesariamente incrementar proporcionalmente los costos logísticos.
- Los modelos clasificadores enfrentaron mayor dificultad para predecir correctamente las clases minoritarias (órdenes con dos y más de tres ítems), lo que refuerza la importancia de técnicas de balanceo como SMOTE en contextos desbalanceados.

Propuestas para uso práctico de los modelos

- El modelo de *Random Forest*, seleccionado por su mejor desempeño, puede ser integrado en el flujo operativo de **Olist** para predecir en tiempo real si una orden será de un solo ítem o múltiple.
- Este modelo puede alimentar módulos de recomendación personalizada, generando sugerencias automáticas de productos complementarios en órdenes con alta probabilidad de ser unitarias.
- Otro uso puede ser en campañas de marketing automatizado, focalizadas en usuarios propensos a hacer compras unitarias, con incentivos para añadir más productos.

En resumen, este modelo que les brindamos puede contribuir al diseño de estrategias logísticas más eficientes. Junto a los insights antes mencionados, se pueden planificar estrategias de marketing incentivar la compra de más productos en una sola orden, aumentando así el valor promedio por pedido y reduciendo los costos asociados a envíos unitarios. Esto representa una oportunidad significativa para Olist de optimizar tanto sus ingresos como su operación logística.

Recomendaciones

Durante el desarrollo del modelo y al análisis exploratorio, se identificaron diversas oportunidades para mejorar la calidad y estructura de los datos, la cual impactaría positivamente en la precisión y utilidad de futuros modelos predictivos.

Primero, se recomienda revisar y depurar la redundancia presente en algunas columnas del dataset, especialmente aquellas que no aportan valor distintivo o que repiten información bajo distinto nombre. La eliminación de estas columnas puede reducir la complejidad del modelo sin sacrificar desempeño.

Asimismo, se detectaron correlaciones altas entre ciertas variables que podrían estar introduciendo ruido o redundancia en el entrenamiento. Es conveniente evaluar la posibilidad de combinar o transformar algunas de estas variables, por ejemplo, mediante técnicas de reducción de dimensionalidad o ingeniería de atributos.

Por otro lado, se identificaron problemas de calidad en los datos, como valores nulos o inconsistentes en campos clave. Reforzar los mecanismos de validación y limpieza al momento de recolectar los datos puede ayudar a minimizar errores que, aunque pequeños, afectan la robustez del modelo.

Finalmente, se sugiere enriquecer los datasets disponibles empezando con brindar más órdenes por usuario, ya que en este caso se trabajó únicamente con una orden por usuario. Además, se podrían recolectar algunas variables que podrían ser más relevantes como el historial agregado del cliente y datos temporales más refinados. Estas mejoras no solo potenciarán el rendimiento del modelo, sino que también abrirán nuevas posibilidades analíticas.